

# EIL Côte d'Opale

## Projet PIC : Apprentissage d'incertitudes dans une méthode pondérée de *machine learning*. Application au démixage et au dématricage conjoints d'images multispectrales

Encadrants : Kinan ABBAS & Matthieu PUIGT  
LISIC, Longuenesse & Bureau A209 Calais  
{kinan.abbas,matthieu.puigt} [at] univ-littoral.fr

Année universitaire 2022-23

Mots-clés : Apprentissage machine, factorisation pondérée en matrices non-négative, démixage, dématricage, restauration de cubes hyperspectraux

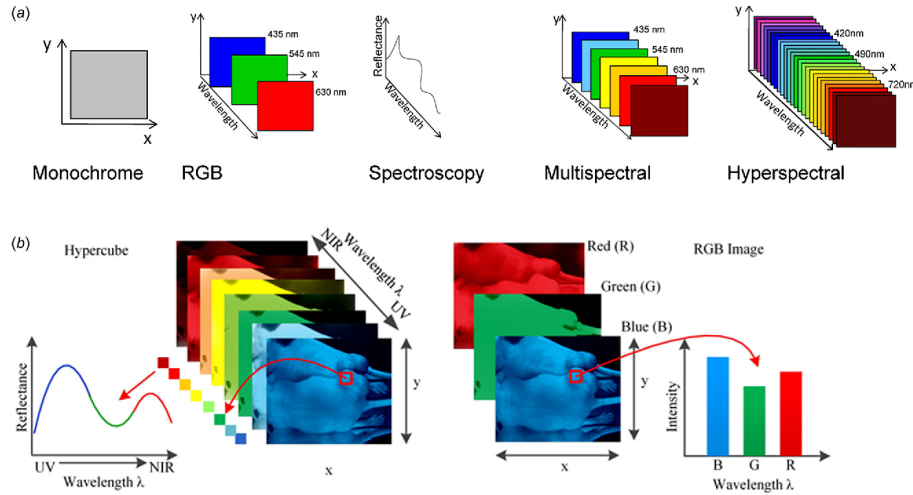


FIGURE 1 – Principe de l'imagerie MS et HS.

## 1 Introduction au sujet

L'imagerie multi- et hyperspectrale (MS / HS) peut être vue comme une technologie combinant les avantages de l'imagerie et de la spectroscopie. En effet, elle étend l'imagerie couleur RVB à un nombre plus important de « couleurs » ou longueurs d'ondes alors qu'elle étend la spectroscopie, ponctuelle, à une couverture spatiale plus large, c.-à-d. une image (voir Fig. 1). Une image MS ou HS peut être vue comme un cube de données avec :

- deux dimensions associées aux informations spatiales ;
- une dimension associée aux informations spectrales.

Ces dernières facilitent la détection, la reconnaissance et la classification des objets ou matériaux observés. La principale différence entre une image MS et une image HS réside dans le nombre de longueurs d'ondes observées, typiquement jusqu'à quelques dizaines pour une image MS et quelques centaines voire milliers pour une image HS (voir Fig. 1).

Depuis quelques années, des imageurs MS et HS miniaturisés ont été proposés et peuvent être facilement embarqués sur des drones. En particulier, dans ce projet PIC, nous nous intéressons à

un imageur dit « snapshot » qui acquiert une image MS en une acquisition, comme un appareil photo classique, voire qui peut acquérir des vidéos.




FIGURE 2 – Principe de l’acquisition « snapshot ». La restauration du cube de données s’appelle le « dématricage » alors que l’estimation des spectres élémentaires qui composent l’image MS est obtenue par « démelange ».

Cependant, la miniaturisation de cet imageur entraîne plusieurs problématiques importantes. Au lieu d’acquérir un cube de données, il acquiert une projection 2D – c.-à-d. une image – du cube (voir Fig. 2). Restaurer le cube à partir de la projection 2D s’appelle le *dématricage*. De nombreuses méthodes ont été proposées pour cela, basées par exemple sur l’interpolation, le filtrage, les approximations de faible rang ou encore le *deep learning* (voir les références dans [1, 2]).

Une autre problématique d’intérêt en imagerie MS ou HS consiste à estimer les spectres élémentaires – ou « endmembers » – des matériaux présents dans l’image. Cette estimation s’appelle « démelange » et de nombreuses méthodes ont été là aussi proposées [3]. Le démelange permet de compter, estimer, localiser les endmembers des matériaux présents dans une scène, même lorsque ces matériaux sont mélangés dans les pixels de l’image. La localisation des endmembers s’effectue via des « cartes d’abondance » estimées en même temps que les endmembers (voir Fig. 3).




FIGURE 3 – Principe du démelange.

Dans nos récents travaux [2], nous avons proposé des approches conjointes qui réalisent en même temps le dématricage et le démelange. Nos résultats montrent notamment une bien meilleure qualité de démelange qu’une approche en deux étapes – qui consisterait en une étape de dématricage suivie d’une étape de démelange – tout en permettant une qualité de dématricage similaire voire supérieure aux approches de la littérature. Ces approches proposées font appel à un formalisme de factorisation matricielle *pondérée* – une famille de méthodes de *machine learning* – dans laquelle les poids sont intimement liés aux systèmes physiques – appelés filtres de Fabry-Perot – qui génèrent l’image 2D à partir de l’image MS 3D.

## 2 Objectifs - Cahier des charges

Dans le cadre de ce projet PIC, nous souhaitons proposer des extensions des méthodes ci-dessus. En effet, ces méthodes supposent que les poids dans la factorisation pondérée sont parfaitement connus. Or, pour de multiples raisons, ce n’est pas le cas en pratique. Au contraire, nous avons seulement une connaissance approximative de ceux-ci.

En conséquence, nous souhaitons apprendre les poids en s’inspirant de la stratégie proposée dans [4]. Plus particulièrement, les étudiants du projet PIC devront :

1. appréhender les méthodes développées dans [2] ;

2. quantifier la chute de performances des méthodes proposées dans [2] lorsque les coefficients de pondération ne sont pas correctement choisis ;
3. implémenter la méthode d'apprentissage des pondération [4] pour corriger les effets observés à l'item précédent.

Les travaux de ce projet PIC s'inscrivent dans les activités en *apprentissage pour le traitement du signal et des images* du LISIC, et plus particulièrement autour de ses activités en imagerie MS et HS dans son antenne de Longuenesse.

En pratique, le projet aura physiquement lieu à Calais, avec des réunions en présentiel et distanciel avec les encadrants. Des méthodes de gestion de projet seront mises en place pour permettre d'atteindre les objectifs fixés. En cas de succès, les étudiants seront associés à la valorisation du travail, par exemple sous forme de publication scientifique.

## Références

- [1] G. Tsagkatakis, M. Bloemen, B. Geelen, M. Jayapala, M., P. Tsakalides, (2018). *Graph and rank regularized matrix recovery for snapshot spectral image demosaicing*. IEEE Transactions on Computational Imaging, 5(2), 301-316.
- [2] Kinan Abbas, Matthieu Puigt, Gilles Delmaire, Gilles Roussel. *Méthode de démelange et dématricage conjoints fondée sur la complétion de rang un pour les images multispectrales « snapshot »*. XXVIIIème Colloque Francophone de Traitement du Signal et des Images (GRETSI), Sep 2022, Nancy, France.
- [3] M. Bioucas-Dias, A. Plaza, N. Dobigeon, M. Parente, Q. Du, P. Gader, J. Chanussot, (2012). *Hyperspectral unmixing overview : Geometrical, statistical, and sparse regression-based approaches*. IEEE Journal on Selected Topics in Applied Earth Observations and Remote Sensing, vol. 5, pp. 354–379.
- [4] J. Wei, C. Tong, B. Wu, Q. He, S. Qi, Y. Yao, Y. Teng (2022). *An Entropy Weighted Nonnegative Matrix Factorization Algorithm for Feature Representation*. IEEE Transactions on Neural Networks and Learning Systems.